

Persona-Aligned LLM NPC Behavior

AS + PAS: 발화와 행동을 동일한 성격 축으로 정렬하기

Bill Verplank Interaction Design Framework 기반 설계 보고서

강채원 2022103383

전 진 2021105731

주민우 2021105647

목 차

1. Introduction

- 1.1 LLM NPC의 가능성과 한계
- 1.2 발화-행동 불일치 문제 정의
- 1.3 본 프로젝트의 전제 · 이유 · 근거

2. Related Work

- 2.1-2.5 기존 접근 검토 / [Table 1] 비교

3. Sketching — 문제 발견과 대안 구성

4. Interaction — Do / Feel / Know

5. Design — Motivation / Meaning / Modes / Mappings

6. Paradigms — Brain / Tool / Media

7. 중요성 (Significance)

8. 필요성 (Necessity)

9. Conclusion

References

1. Introduction

1.1 LLM NPC의 가능성과 한계

LLM을 게임 NPC에 적용하면 기존 스크립트 기반 NPC보다 훨씬 자연스럽고 유연한 상호작용이 가능하다. LLM 기반 NPC는 플레이어가 예상하지 못한 질문을 하거나 새로운 상황을 제시하더라도 자연어로 응답을 생성할 수 있어, 내러티브 RPG·텍스트 어드벤처·오픈월드 게임 등 다양한 장르에서 주목받고 있다[1][5].

그러나 LLM NPC가 실제 게임 캐릭터로 기능하기 위해서는 언어적 자연스러움만으로는 충분하지 않다. 플레이어는 NPC가 어떤 말을 했는지뿐 아니라 그 말 이후 어떤 행동을 선택했는지, 이전 상황과 현재 행동이 얼마나 일관적인지, 어떤 행동 패턴을 반복하는지를 종합적으로 판단한다[5][13][14]. 따라서 LLM NPC의 품질은 언어적 자연스러움뿐 아니라 행동 일관성에 의해 결정된다.

1.2 발화-행동 불일치 문제 정의

본 프로젝트가 주목하는 문제는 LLM NPC의 발화와 행동이 서로 어긋나는 현상이다. NPC가 자신을 "냉혹한 용병"이라고 소개하고 공격적인 대사를 생성했음에도 실제 행동 선택에서는 협상이나 양보를 선택한다면, 플레이어는 그 NPC를 일관된 인격체로 받아들이기 어렵다. 본 프로젝트는 이 현상을 발화-행동 불일치(speech-action inconsistency)로 정의한다[2][3]. 이 불일치는 캐릭터성·몰입감·서사 일관성의 붕괴로 이어지며, 일반 LLM 연구에서도 말로 선언한 원칙과 실제 선택이 일치하지 않는 words-deeds inconsistency로 보고된다[15][16][17][18].

1.3 본 프로젝트의 전제 · 이유 · 근거

본 보고서가 제안하는 AS+PAS 구조는 다음의 전제, 이유, 근거에 기반한다.

전제 1. NPC의 설득력은 말투가 아니라 반복된 행동 패턴에서 나온다.

플레이어는 NPC의 자기소개 문장이나 일회성 대사만으로 캐릭터를 판단하지 않는다. 어떤 상황에서 어떤 선택을 반복하는지, 감정 반응과 행동이 얼마나 일관적인지를 종합적으로 판단한다. Generative Agents[5]는 LLM 에이전트를 memory, reflection, planning을 가진 시뮬레이션 객체로 설계함으로써, 에이전트의 설득력이 단발성 발화가 아니라 누적된 기억과 행동 패턴에서 구성된다는 점을 보여준다.

전제 2. 말·가치 선언과 실제 행동 선택은 별개로 다루어야 한다.

LLM이 특정 성격이나 가치관을 말로 선언한다고 해서 실제 상황에서 그에 맞는 행동을 선택한다고 볼 수 없다. Large Language Models Often Say One Thing and Do Another[15]는 word-based question과 deed-based question을 대응시켜 평가했으며, 여러 영역에서 말과 행동의 불일치가 나타남을 보였다. Mind the Value-Action Gap[16] 역시 LLM이 특정 가치에 동의한다고 말하더라도 실제 행동 선택은 그 가치와 다를 수 있음을 보여준다.

전제 3. 장기 persona drift와 단일 결정 시점의 발화-행동 mismatch는 다른 문제다.

장기 persona drift는 긴 대화 과정에서 NPC의 정체성이 서서히 흐트러지는 문제다. 반면 본 프로젝트가 다루는 speech-action mismatch는 한 결정 시점에서 발화와 행동이 어긋나는 문제다. LLM Agents in Interaction[13]과 Examining Identity Drift[14]는 장기 상호작용에서 persona consistency가 흔들릴 수 있음을 보여주지만, 본 프로젝트는 그 중에서도 단일 결정 시점의 정렬 문제에 초점을 둔다.

이유 · 근거

성격 표현 능력이 행동 선택 정렬을 보장하지 않는다. PersonaLLM[1]은 LLM이 Big Five 기반 persona를 언어적으로 표현할 수 있음을 보여주지만, Is Self-knowledge and Action Consistent or Not[3]은 자기보고 성격과 실제 행동 경향이 일치하지 않을 수 있음을 보여주며, The Personality Illusion[17]은 persona injection이 behavior에는 일관되지 않은 효과만 보일 수 있음을 지적한다. Editing Personality for LLMs 관련 측정에서 자기보고와 행동 선택의 일치율은 인간이 84% 이상인 데 비해 LLM은 55% 이하였으며, Character is Destiny[2]의 의사결정 실험에서 인간이 92.01%를 기록한 반면 LLM은 70~80% 수준에 그쳤다. 또한 ASA[12]는 내부 표현에 특정 의도가 존재하더라도 그것이 실제 decision으로 자동 연결되지 않을 수 있음을 보여주며, 이는 PAS와 같은 선택 단계 보정이 필요한 직접적인 근거가 된다.

이러한 전제와 근거를 바탕으로 본 프로젝트는 LLM NPC의 persona alignment를 "성격처럼 말하게 만드는" 문제가 아니라 "성격에 맞는 행동을 선택하게 만드는" 문제로 재정의한다. 이를 위해 표현 단계에서 내부 표현을 persona 방향으로 유도하는 AS와, 행동 선택 단계에서 후보 행동을 같은 persona axis로 다시 정렬하는 PAS를 결합한다.

2. Related Work

본 절에서는 LLM persona 제어와 관련된 다섯 가지 접근 방식을 검토하고, 각 방식이 어느 층위에 개입하며 어떤 한계를 갖는지를 정리한다.

2.1 Prompt-based Persona Injection

System prompt나 character profile을 통해 성격을 자연어로 주입하는 방식이다. 구현이 쉽고 런타임 교체가 가능하지만, 입력 텍스트를 통한 간접 제어이기 때문에 주로 발화 스타일에 영향을 준다. LLM이 성격을 언어적으로 표현할 수 있음을 보여준 PersonaLLM[1]도 실제 행동 선택까지 안정적으로 반영된다는 의미는 아니다[3][17].

2.2 Fine-tuning Approaches

캐릭터별 데이터를 모델 가중치에 반영하는 방식이다. Character-LLM[6], CoSER[7], Neeko[8], P-React[21]이 역할 수행 능력 강화를 위한 다양한 접근을 제안한다. 그러나 캐릭터마다 별도 학습이 필요해 수많은 NPC가 존재하는 게임 환경에서는 비용과 확장성 측면에서 한계를 가진다.

2.3 Memory / Architecture Approaches

NPC가 이전 대화·관계·사건을 기억하고 이를 바탕으로 행동하도록 설계한다. Generative Agents[5]는 memory, reflection, planning 구조를 통해 장기적 행동 일관성을 구성한다. 그러나 이 방식은 "이번 발화와 이번 행동이 같은 persona 방향인가"를 단일 결정 시점에서 직접 보장하지는 않는다[13][14].

2.4 Activation Steering & Linear Representation

CAA[9]는 긍정/부정 예시 쌍의 activation 차이를 평균해 steering vector를 만들고, 이를 추론 중 내부 표현에 더해 행동 경향을 조절한다. LRH[10]는 고수준 개념이 내부 표현 공간에서 선형

방향으로 근사될 수 있다는 이론적 기반을 제공하며, EAST[11]는 activation steering이 agent의 행동 분포에 영향을 줄 수 있음을 보여준다. 그러나 내부 표현에 편향이 생기더라도 그 신호가 최종 행동 선택 단계에서 희석될 수 있으며, ASA[12]는 이 점을 직접 지적한다.

2.5 Words–Deeds Inconsistency in LLMs

Large Language Models Often Say One Thing and Do Another[15], Mind the Value-Action Gap [16], The Personality Illusion[17], Probing Stable Internal Beliefs[18], Persistent Instability in Personality Measurements[19]는 각각 LLM의 말–행동 불일치, 가치–행동 괴리, 성격 자기보고와 행동의 분리, 내부 신념의 불안정성을 체계적으로 보고한다. 이러한 흐름은 본 프로젝트의 문제 정의가 게임 NPC에 특수한 현상이 아님을 뒷받침한다.

[Table 1] 기존 접근의 개입 층위와 한계

접근 방식	개입 층위	런타임 변경	단일 시점 정렬	주요 한계
Prompt	입력 텍스트	○	△	말투 위주, 행동 선택 보장 어려움[1][3]
Fine-tuning	모델 가중치	×	○	캐릭터별 학습 비용, 확장성 제한[6][7][8]
Memory / Architecture	장기 맥락	○	×	단일 결정 시점 정렬 직접 보장 못 함[5][13]
Activation Steering	내부 표현	○	△	토큰 생성 단계에서 신호 희석[9][12]
AS + PAS (본 프로젝트)	표현 + 선택 모두	○	○	개입 layer k 선택 등 추가 검증 필요

Table 1. 기존 접근 방식의 개입 층위 비교. ○: 가능 / △: 부분적 / ×: 어려움.

Table 1이 보여주듯, 기존 접근은 각각 단일 층위에 개입하며 "단일 결정 시점에서 발화와 행동을 같은 persona axis로 정렬한다"는 요구를 직접 충족하지 못한다. 본 프로젝트의 AS+PAS는 이 공백을 표현 단계와 선택 단계 양쪽에서 메우는 설계다.

3. Sketching — 문제 발견과 대안 구성

3.1 Beyond Craft to Design

본 프로젝트의 Sketching 단계는 LLM NPC의 발화-행동 불일치 문제를 즉각적인 구현 문제로 다루기보다, 기존 접근들이 각각 어떤 층위에서 작동하고 어떤 한계를 갖는지 분석하는 데서 출발했다. 이 분석은 표현 단계와 선택 단계 양쪽에 동시 개입하는 구조가 필요하다는 결론으로 이어졌다.

3.2 Alternatives: AS-only / PAS-only / AS+PAS

단일 설계안만 발전시키면 비교 기준이 소실되고 설계 결정의 타당성을 검증할 수 없다. 이에 본 프로젝트는 다음 세 조건을 초기부터 병렬로 설계했다.

- AS-only: 표현 단계 개입만으로 행동 정렬이 가능한지 확인. activation steering 단독의 효과를 측정한다.
- PAS-only: 내부 표현 개입 없이 선택 단계 보정만으로 충분한지 확인. 원래 hidden state 와 행동 후보 embedding 의 cosine similarity 로 행동을 선택한다.
- AS+PAS: 두 개입이 결합되었을 때 발화-행동 일치도가 실제로 개선되는지를 확인하는 핵심 조건.

이 세 조건을 병렬로 설계함으로써 어느 층위의 개입이 실질적으로 기여하는지를 인과적으로 분리할 수 있다. 이는 Verplank가 강조하는 alternatives의 중요성에 해당한다.

4. Interaction — Do / Feel / Know

4.1 사용자 집단 정의

본 프로젝트의 사용자는 게임 디자이너와 플레이어 두 집단으로 나뉜다. 게임 디자이너는 NPC의 persona와 행동 경향을 설계·조정하는 사용자이고, 플레이어는 그 결과로 생성되는 NPC의 발화와 행동을 경험하는 사용자다. 두 집단은 같은 시스템과 관계하지만 조작 대상, 피드백, 지식 모델이 다르다.

4.2 Do — 입력

게임 디자이너의 주요 입력은 persona vector(v_{persona})와 steering strength(α), 그리고 행동 후보 설계다. v_{persona} 는 "공격적인 용병"과 "협조적인 용병"처럼 대비되는 예시 쌍을 LLM에 입력했을 때 생성되는 내부 활성화값의 차이를 평균하여 추출한다. α 는 v_{persona} 의 적용 강도를 실시간으로 조절하는 연속 파라미터로, α 과대 시 mode collapse가 발생할 수 있다[11]. v_{persona} 자체는 모델 재학습 없이 런타임에서 즉시 교체 가능하며, 새 캐릭터마다 재학습이 필요한 fine-tuning 기반 접근과 차별화된다. 플레이어의 입력은 대화·전투 선택지 등 일반적인 게임 조작이며, AS+PAS는 플레이어 입장에서 보이지 않는 제어층으로 작동한다[5].

4.3 Feel — 피드백 (Hot vs Cool Media)

플레이어에게는 hot 미디어가 제공된다. NPC의 발화 텍스트와 행동 애니메이션은 완결된 형태로 즉각 출력되며, 플레이어는 내부 알고리즘을 이해하지 않고도 결과를 경험한다. 반복된 상호작용을 통해 NPC의 행동 패턴에 대한 신뢰가 형성된다. 디자이너에게는 cool 미디어가 제공된다. α 와 v_{persona} 를 조정하고 그 결과를 직접 확인하며 방향성을 수정하는 과정은, 시스템이 정답을 제시하지 않기 때문에 디자이너의 능동적 판단과 개입을 요구한다.

4.4 Know — 지식 모델 (Path vs Map Knowledge)

플레이어는 path knowledge를 형성한다. "이 NPC는 공격적이니 다음에도 공격을 선택할 것이다"라는 단계별 예측이 반복 상호작용을 통해 구축되며, 발화와 행동의 단 한 번의 불일치만으로도 이 예측 구조가 붕괴한다. 본 프로젝트가 해결하고자 하는 것이 이 붕괴 지점이다. 디자인어는 map knowledge를 필요로 한다. $v_persona$ 가 어떤 행동 분포를 만들고, α 변화가 action entropy에 어떤 영향을 주며, PAS 적용이 행동 선택을 어떻게 바꾸는지를 전체적으로 파악해야 하며, 이 지식은 반복적인 조정 과정을 통해 형성된다[9][10][11][12].

5. Design — Motivation / Meaning / Modes / Mappings

5.1 Motivation — Error & Idea

본 프로젝트의 motivation은 발화-행동 불일치라는 측정 가능한 error에서 출발한다. Editing Personality for LLMs 관련 측정에서 인간의 자기보고-행동 일치율은 84% 이상이었으나 LLM은 55% 이하였으며, Character is Destiny[2]의 의사결정 실험에서 인간이 92.01%를 기록한 반면 LLM은 70~80% 수준에 그쳤다. PersonaLLM[1]이 LLM의 성격 표현 가능성을 보여준 것과 달리, [2][3][15][17]은 그 표현이 실제 행동 선택과는 구조적으로 분리될 수 있음을 보여준다. 이에 대한 idea는 동일한 persona 방향을 발화 생성 단계와 행동 선택 단계에 모두 적용하는 것이다. AS는 내부 표현을 persona 방향으로 이동시키고, PAS는 행동 후보 중 그 내부 표현과 가장 잘 정렬된 행동을 선택한다. 추가 학습 없이 런타임에서 실현 가능하다는 점이 기존 접근들이 채우지 못한 공백이다.

5.2 Meaning — 나침반과 이중 필터

v_{persona} 벡터는 LLM 내부 표현 공간에 방향을 부여하는 나침반과 같고, α 는 자기장 세기에 해당한다. Fine-tuning이 나침반 자체를 새로 제작하는 것이라면, AS는 기존 나침반에 외부 자석을 대는 것에 해당한다. 모델 가중치를 수정하지 않는다는 점이 핵심이다. AS는 내부 표현을 성격 방향으로 편향시키는 1차 필터이고, PAS는 그 편향된 표현이 어느 행동으로 귀결될지를 성격 축에 맞게 확정하는 2차 필터다. 1차 필터 단독으로는 토큰 생성 과정에서 언어 통계적 패턴이 성격 신호를 덮어쓸 수 있으며[9][12], 2차 필터가 선택 단계에서 이를 재보정한다.

5.3 Modes — AS · PAS 수식

$$\text{AS: } h' = h + \alpha \cdot v_{\text{persona}}$$

특정 layer k 의 내부 표현 h 에 persona vector를 더해 표현 공간을 persona 방향으로 이동시킨다. h' 는 조정된 내부 표현, α 는 적용 강도다[9][10].

$$\text{PAS: } a^* = \operatorname{argmax}_a \cos(h', e_a)$$

AS로 조정된 내부 표현 h' 와 사전 계산된 행동 후보 embedding e_a 간 cosine similarity로 최적 행동 a^* 를 선택한다. 두 수식의 핵심은 동일한 persona 벡터가 표현과 선택 두 단계에 같은 방향으로 작용한다는 구조적 대칭이다. 행동 임베딩이 사전에 계산되어 있기 때문에 PAS 단계에서 추가 지연이 발생하지 않는다. 단, 개입 layer k 의 최적값은 추가 실험이 필요한 설계 변수로 남는다.

5.4 Mappings — Control · Display · 평가 지표

사용자	Control (입력)	Display (출력)
Game Designer	α 슬라이더, v_{persona} 교체, 행동 후보 설계	발화·행동, 행동 분포, action entropy, 발화·행동 일치도
Player	대화·전투 선택지	NPC 발화 텍스트 + 행동 애니메이션

Table 2. 사용자별 Control-Display 매핑.

Ground truth는 시나리오별 행동 후보에 대해 사전에 정의한 label이다. 행동 후보를 aggressive ↔ cooperative 축에서 -2(사과·양보) ~ +2(즉시 공격)로 점수화하여, 모델이 선택한 행동이 목표 persona와 얼마나 일치하는지를 정량 평가한다. 평가 지표는 다음과 같다.

- Target Persona-Axis Alignment: 선택된 행동이 목표 persona 축과 얼마나 일치하는지 측정.

- Speech–Action Agreement: 발화 tone label 과 행동 label 이 같은 방향인지 확인. words–deeds inconsistency[15][16]를 NPC 맥락에서 직접 측정하는 핵심 지표.
- Action Entropy: 특정 행동으로만 붕괴하지 않고 행동 다양성이 유지되는지 확인. mode collapse 감지 지표[11].
- Action Distribution Shift: AS/PAS 적용 전후 행동 분포가 persona 방향으로 이동했는지 비교.

6. Paradigms — Brain / Tool / Media

6.1 Brain — LLM 의 위치와 한계

Brain 패러다임은 컴퓨터를 전자 두뇌로 규정하고 지능과 자율성을 목표로 한다. LLM은 자율적 언어 생성과 추론 능력이 그 핵심이다. 그러나 PersonaLLM[1]이 LLM의 성격 표현 능력을 보여준 것과 달리, Character is Destiny[2]와 Ai et al.[3]은 성격 표현과 행동 선택이 다른 문제임을 보여준다. 자율적 언어 생성 능력이 행동 선택의 일관성을 보장하지 않는다는 것이 Brain 패러다임만으로 접근했을 때의 구조적 한계다.

6.2 Tool — AS+PAS 제어층

Tool 패러다임은 컴퓨터를 인간 능력의 확장 도구로 보고 직접 조작을 통한 역량 강화를 목표로 한다. AS+PAS는 LLM 자체는 그대로 두되, 그 위에 게임 디자이너가 직접 조작 가능한 제어층위를 추가한다[9][10][11][12]. Fine-tuning과 달리 모델 가중치를 재학습하지 않고, memory와 달리 장기 맥락만을 다루는 것이 아니라 단일 결정 시점의 행동 선택까지 조정한다는 점에서 차별적이다.

6.3 Media — 플레이어 경험

Media 패러다임은 컴퓨터를 커뮤니케이션의 매체로 보고 몰입과 참여를 목표로 한다. 성격이 일관된 NPC는 플레이어를 서사에 몰입시키는 미디어로 작동하고, 발화-행동 불일치는 그 몰입을 파괴하는 노이즈로 작용한다[5][13][14]. AS+PAS는 이 노이즈를 구조적으로 제거함으로써 미디어로서의 NPC 기능을 회복시킨다.

6.4 패러다임 통합 구조

층위	패러다임	역할	주요 행위자
상위	Media	몰입적 게임 서사 경험	Player
중위	Tool	AS+PAS 직접 제어 인터페이스	Game Designer
하위	Brain	자율적 언어·추론 능력 제공	LLM (NPC)

Table 3. Brain-Tool-Media 3층 통합 구조.

Brain 위에 Tool을 얹고 그 결과가 Media로 출력되는 이 3층 구조는, 기존 접근들이 각각 단일 패러다임에 머물렀던 것과 구별된다. Prompt와 fine-tuning은 Brain 내부 조작에 그치고, memory와 단순 활성값 조작은 Tool의 일부 기능만을 구현한다. AS+PAS는 세 패러다임을 수직으로 통합하는 구조다.

7. 중요성 (Significance)

7.1 게임 NPC 측면 — 캐릭터 신뢰도와 몰입의 핵심

LLM NPC의 발화-행동 불일치는 단순한 출력 오류가 아니라 캐릭터 신뢰도·몰입감·서사 일관성과 직접 연결된다. 플레이어는 NPC가 어떤 말을 했는지 뿐만이 아니라 그 말 이후 어떤 행동을 선택했는지, 반복 상호작용 속에서 일관된 행동 패턴을 유지하는지를 함께 판단한다 [5][13][14]. 특히 내러티브 RPG·텍스트 어드벤처·대화 중심 게임에서 NPC의 행동 선택은 이야기 전개와 플레이어 경험에 직접적인 영향을 주기 때문에, 발화-행동 정렬은 향후 LLM NPC 시스템의 핵심 품질 기준이 될 수 있다.

7.2 학술적 기여 — persona 연구 흐름에서의 위치와 LLM 신뢰성

본 주제는 기존 persona 연구의 한계를 행동 선택 단계까지 확장한다. PersonaLLM [1]은 LLM의 성격 표현 가능성을 보여주지만, Character is Destiny[2], Is Self-knowledge and Action Consistent[3], The Personality Illusion[17]은 self-report나 persona injection이 실제 behavior를 안정적으로 보장하지 못할 수 있음을 보여준다. 본 프로젝트는 persona alignment를 발화 스타일 제어가 아니라 persona-driven action selection의 문제로 재정의한다. 나아가 Large Language Models Often Say One Thing and Do Another[15]와 Mind the Value-Action Gap[16]이 보고하는 일반 LLM의 말-행동 불일치 문제를 게임 NPC라는 구체적 상호작용 맥락에 적용했다는 점에서, 본 주제는 LLM 기반 상호작용 시스템 전반의 신뢰성 연구와도 연결된다.

7.3 기존 방식 대비 차별성

본 프로젝트의 차별성은 표현 단계와 선택 단계에 동시에 개입한다는 점에 있다. Prompt 방식은 말투 위주 제어에 머무르고[1], fine-tuning 방식은 캐릭터별 학습 비용과 확장성 문제가 있으며[6][7][8][21], Memory 기반 접근은 단일 결정 시점에서 발화와 행동의 일치를 직접 보장하지 못하고[5][13][14], Activation Steering은 최종 행동 선택 단계에서 신호가 희석될 수 있다[9][12]. 본 프로젝트는 AS와 PAS를 결합함으로써 기존 방식들이 충분히 다루지 못한 선택 단계의 공백을 보완한다. 방법론적으로 CAA[9], LRH[10], EAST[11], ASA[12]의 흐름을 기반으로, persona vector, hidden state, action embedding, cosine similarity라는 명확한 구성 요소를 가진 interaction design 결과물이다.

8. 필요성 (Necessity)

8.1 LLM NPC 품질 기준과 적용 장르

LLM NPC는 기존 스크립트 기반 NPC보다 자유롭고 유연한 대화를 제공할 수 있지만, 그 자유도가 높아질수록 캐릭터 설정과 충돌하는 행동을 선택할 가능성도 커진다. 내러티브 RPG·텍스트 어드벤처·대화 중심 게임에서 발화-행동 정렬은 선택이 아닌 품질 기준이다. NPC가 자신의 persona에 맞는 행동을 일관되게 선택할 때, 플레이어는 그 NPC를 예측 가능하고 신뢰할 수 있는 캐릭터로 받아들이게 된다.

8.2 실험 설계와 평가 체계의 활용 가능성

AS+PAS 구조는 AS-only / PAS-only / AS+PAS의 ablation 비교를 통해 실험적으로 검증할 수 있다. Character is Destiny[2]와 Large Language Models Often Say One Thing and Do Another[15]를 참고한 ground truth 기반 평가 체계(Target Persona-Axis Alignment, Speech-Action Agreement, Action Entropy)는 NPC 행동 QA, 캐릭터별 persona 튜닝, 시나리오 밸런싱, 장르별 NPC 반응 설계 등 실제 게임 개발 과정에서 활용될 수 있다.

8.3 확장 가능성

현재 프로젝트는 aggressive ↔ cooperative라는 단일 target persona axis를 중심으로 설계되지만, 향후 cautious, loyal, selfish 등 여러 성격 축으로 확장할 수 있다. 기본 성격, 관계 상태, 현재 감정 등을 각각의 vector로 구성하고 상황에 따라 가중치를 조절하는 복합 persona 설계가 가능하며, 게임 NPC뿐 아니라 가상 캐릭터·디지털 휴먼·멀티에이전트 시뮬레이션 등 다양한 LLM agent 시스템에도 적용 가능한 설계 방향이다.

9. Conclusion

본 보고서는 Bill Verplank의 IxD process에 따라 Persona-Aligned LLM NPC Behavior 프로젝트를 정리하였다. Sketching에서는 기존 4개 접근의 구조적 한계를 분석하고 표현·선택 단계 동시 개입이라는 설계 방향을 도출하였다. Interaction에서는 게임 디자이너와 플레이어의 입력, 피드백(hot/cool media), 지식 모델(path/map knowledge)을 Do, Feel, Know로 구분하였다. Design에서는 발화-행동 불일치라는 측정 가능한 error, 나침반·이중 필터 은유, AS+PAS 수식, control-display mapping과 ground truth 기반 평가 체계를 정리하였다. Paradigms에서는 Brain-Tool-Media의 3층 수직 통합 구조로 해석하였다.

본 프로젝트의 핵심 주장은 LLM NPC의 persona alignment가 "성격처럼 말하게 만드는" 문제가 아니라 "성격에 맞는 행동을 선택하게 만드는" 문제라는 점이다. AS+PAS는 이를 위해 동일한 persona 축을 표현 단계와 선택 단계에 모두 적용하는 설계 방향을 제안하며, 개입 layer k 의 최적값 및 v_{persona} 추출 품질은 후속 실험에서 검증되어야 할 파라미터로 남는다.

References

- [1] Jiang, H., Zhang, X., Cao, X., Breazeal, C., Roy, D., & Kabbara, J. (2024). PersonaLLM: Investigating the Ability of Large Language Models to Express Personality Traits. Findings of NAACL 2024.
- [2] Xu, R., Wang, X., Chen, J., Yuan, S., et al. (2024). Character is Destiny: Can Role-Playing Language Agents Make Persona-Driven Decisions?
- [3] Ai, Y., He, Z., Zhang, Z., Zhu, W., et al. (2024). Is Self-knowledge and Action Consistent or Not: Investigating Large Language Model's Personality.
- [4] Klinkert, L. J., Buongiorno, S., & Clark, C. (2024). Driving Generative Agents With Their Personality.
- [5] Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative Agents: Interactive Simulacra of Human Behavior. UIST 2023.
- [6] Shao, Y., Li, L., Dai, J., & Qiu, X. (2023). Character-LLM: A Trainable Agent for Role-Playing. EMNLP 2023.
- [7] Wang, X., et al. (2025). CoSER: Coordinating LLM-Based Persona Simulation of Established Roles.
- [8] Yu, X., Luo, T., Wei, Y., Lei, F., et al. (2024). Neeko: Leveraging Dynamic LoRA for Efficient Multi-Character Role-Playing Agent. EMNLP 2024.
- [9] Rimsky, N., Gabrieli, N., Schulz, J., Tong, M., Hubinger, E., & Turner, A. (2024). Steering Llama 2 via Contrastive Activation Addition. ACL 2024.
- [10] Park, K., Choe, Y. J., & Veitch, V. (2024). The Linear Representation Hypothesis and the Geometry of Large Language Models. ICML 2024.
- [11] Rahn, N., D'Oro, P., & Bellemare, M. G. (2024). Controlling Large Language Model Agents with Entropic Activation Steering.
- [12] Wang, Y., et al. (2026). ASA: Training-Free Representation Engineering for Tool-Calling Agents.
- [13] Frisch, I., & Giulianelli, M. (2024). LLM Agents in Interaction: Measuring Personality Consistency and Linguistic Alignment. PERSONALIZE 2024.
- [14] Choi, J., Hong, Y., Kim, M., & Kim, B. (2024). Examining Identity Drift in Conversations of LLM Agents.
- [15] Xu, R., Lin, H., Han, X., Zheng, J., et al. (2025). Large Language Models Often Say One Thing and Do Another. ICLR 2025.
- [16] Shen, H., Clark, N., & Mitra, T. (2025). Mind the Value-Action Gap: Do LLMs Act in Alignment with Their Values?
- [17] Han, P., Kocielnik, R., Song, P., et al. (2025). The Personality Illusion: Revealing Dissociation Between Self-Reports & Behavior in LLMs.
- [18] Luo, Y., Xu, K., Lu, Y., Yuan, Y., & Yao, A. C.-C. (2025). Probing the Lack of Stable Internal Beliefs in LLMs.
- [19] Tosato, T., et al. (2026). Persistent Instability in LLM's Personality Measurements.
- [20] Wang, Z., et al. (2026). Why Reasoning Fails to Plan: A Planning-Centric Analysis of Long-Horizon

Decision Making in LLM Agents.

- [21] Dan, Y., Zhou, J., Chen, Q., Tian, J., & He, L. (2025). P-React: Synthesizing Topic-Adaptive Reactions of Personality Traits via Mixture of Specialized LoRA Experts.